INF721 2023/2



Aprendizado em Redes Neurais Profundas

A6: Multilayer Perceptron (MLP)

Logística

Avisos

▶ Teste T1: Regressão Logística será corrigido até o final de semana

Última aula

- Regressão Logística em Numpy
- Vetorização
- Gradientes da Regressão Logística

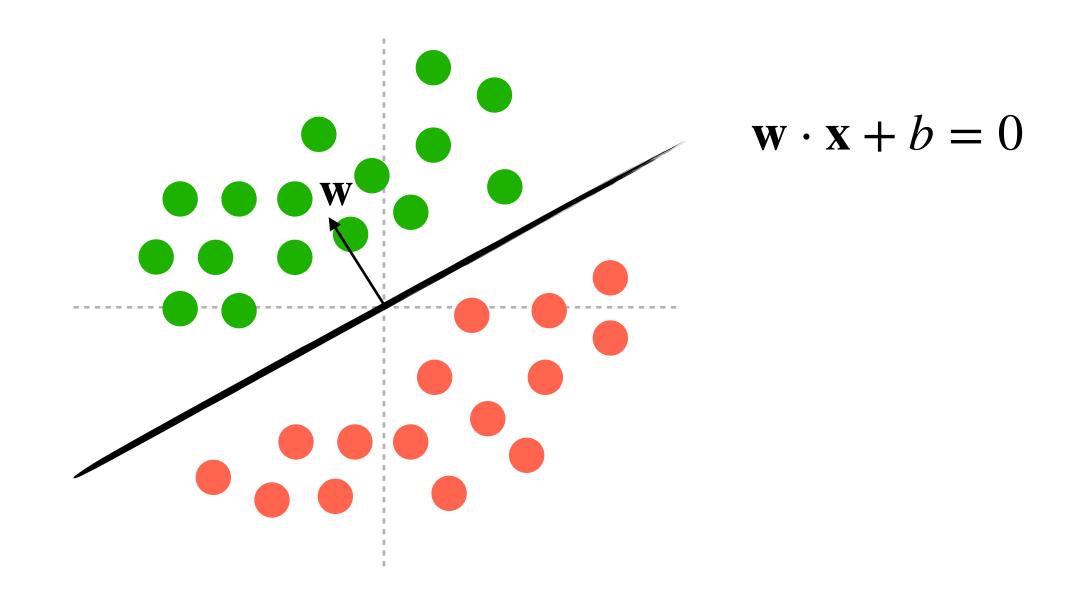


Plano de Aula

- Problemas linearmente separáveis
- Perceptron
- Problemas linearmente não-sepáveis
- Multilayer Perceptron (MLP)
 - Intuição e formalização
 - Propagação das entradas (forward pass)

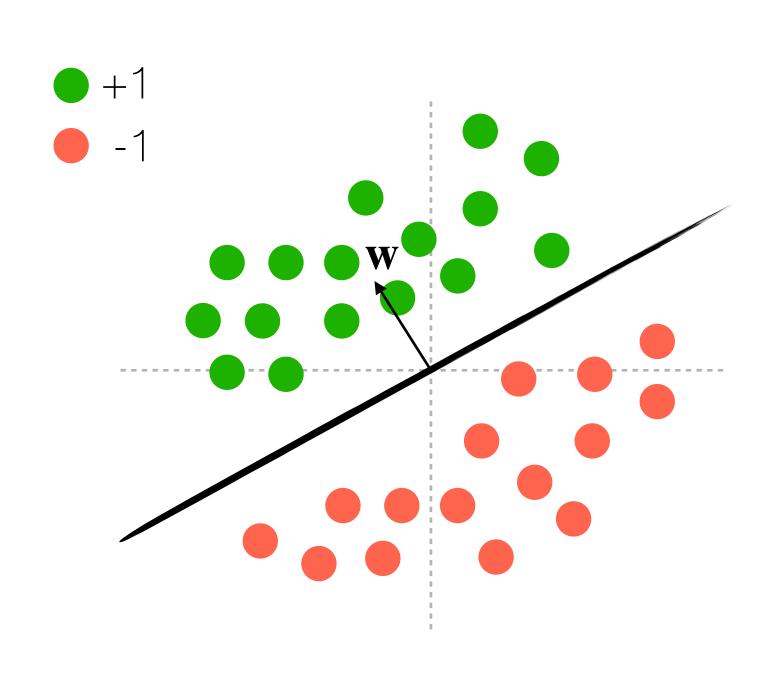


Problemas Linearmente Separáveis





Problemas Linearmente Separáveis



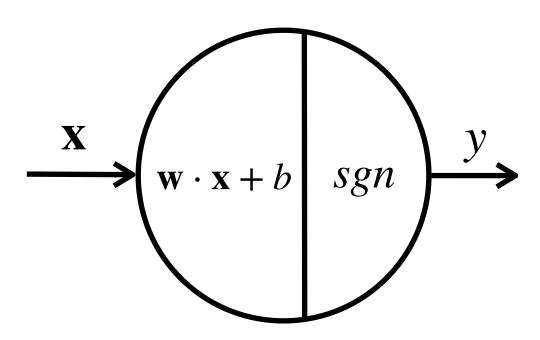
$$sgn(z) = \begin{cases} 1, & z > 0 \\ -1, & z < 0 \end{cases}$$

$$h(\mathbf{x}) = sgn(\mathbf{w} \cdot \mathbf{x} + b)$$

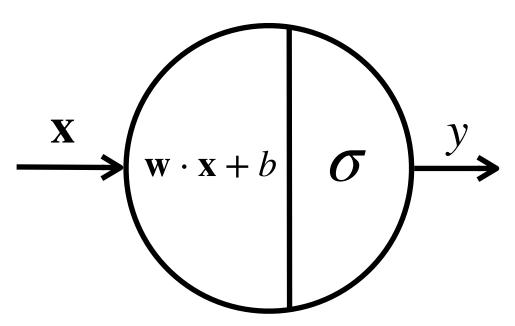


Problemas Linearmente Separáveis

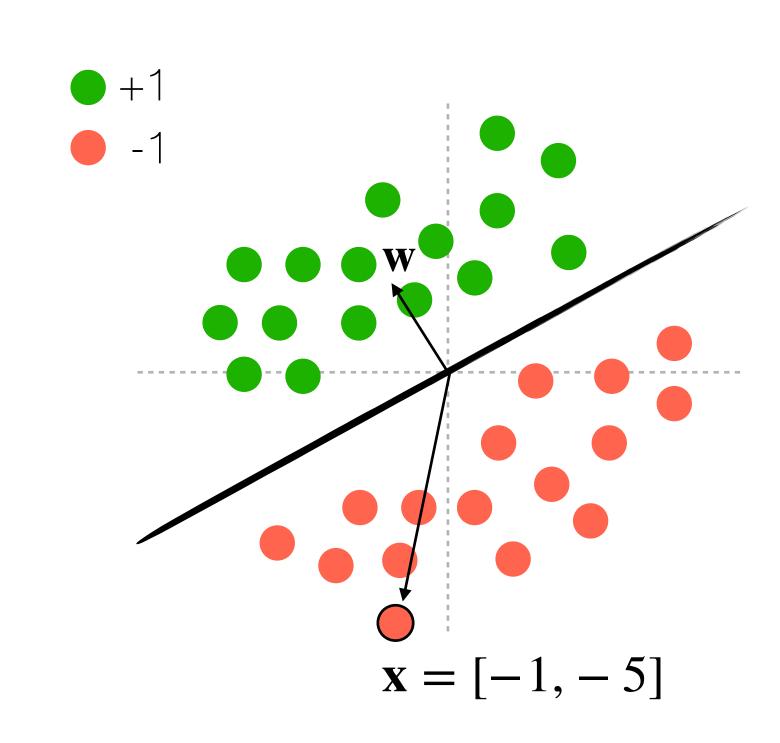
Perceptron



Regressão Logística



Ambos aprendem apenas fronteiras de decisão lineares!



$$sgn(z) = \begin{cases} 1, & z > 0 \\ -1, & z < 0 \end{cases}$$

$$h(\mathbf{x}) = sgn(\mathbf{w} \cdot \mathbf{x} + b)$$

$$\mathbf{w} = [-2,1]$$

$$b = 0$$

$$h(\mathbf{x}) = sgn(-2 \cdot -1 + 1 \cdot (-5) + 0)$$

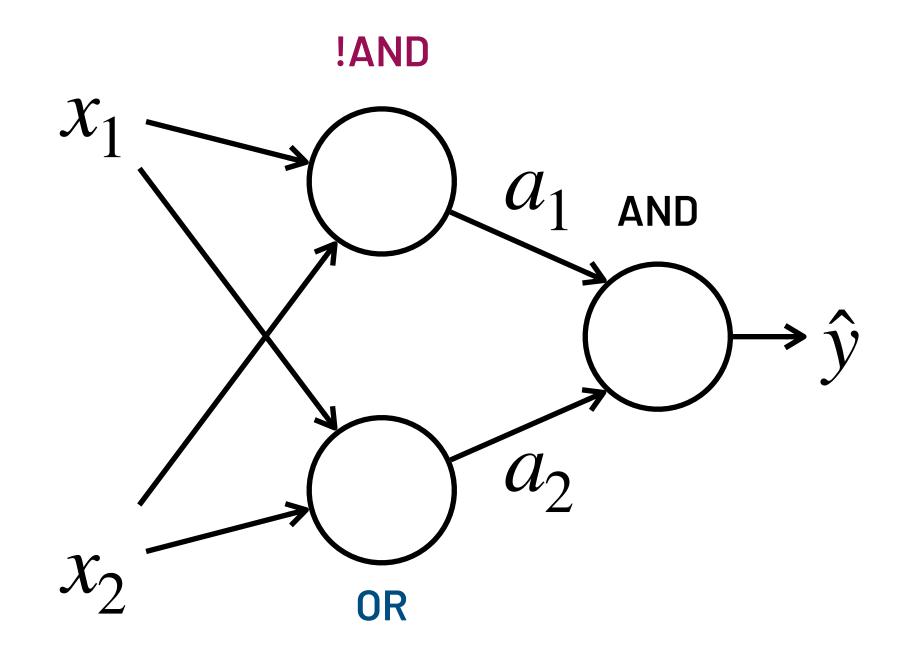
$$h(\mathbf{x}) = sgn(-3)$$

$$h(\mathbf{x}) = -1$$



Problemas Não-linearmente Separáveis

$$f(x_1, x_2) = x_1 \text{ XOR } x_2$$



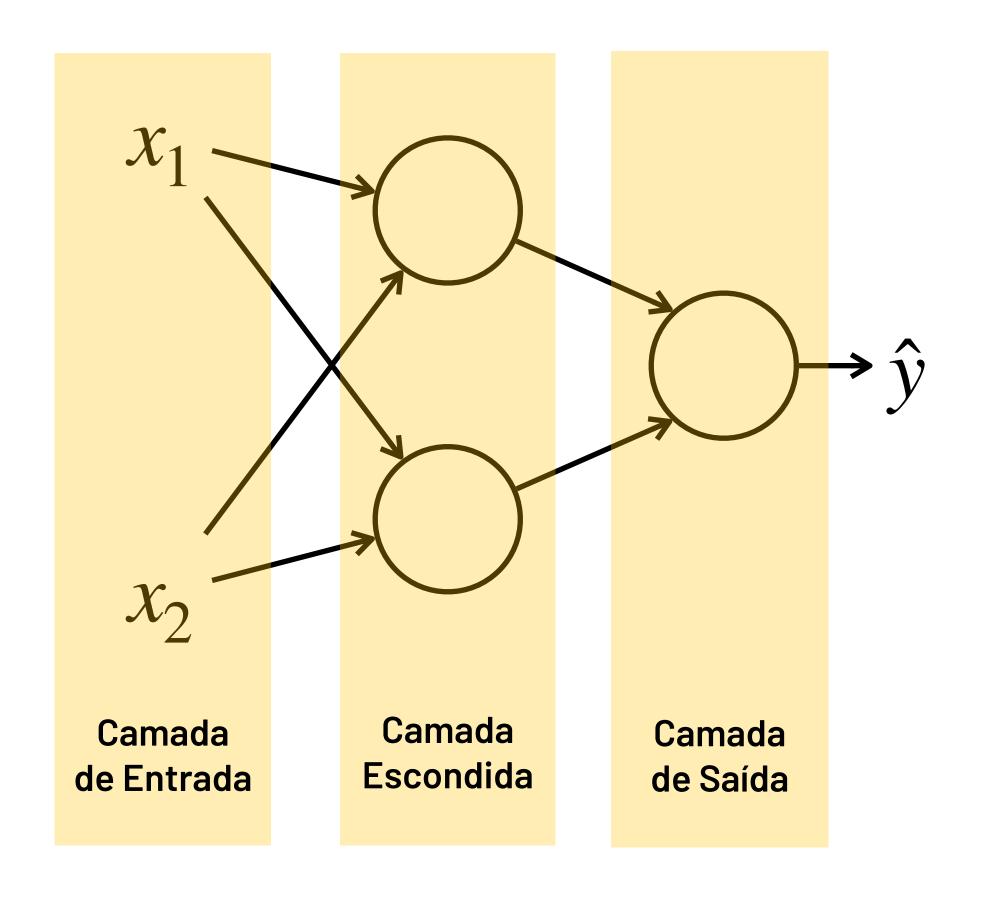
RNAs aprendem representações intermediárias $\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}$ dos dados de entrada $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$, chamadas

representações latentes, que podem tornar um problema não-linearmente separável em linearmente separável!

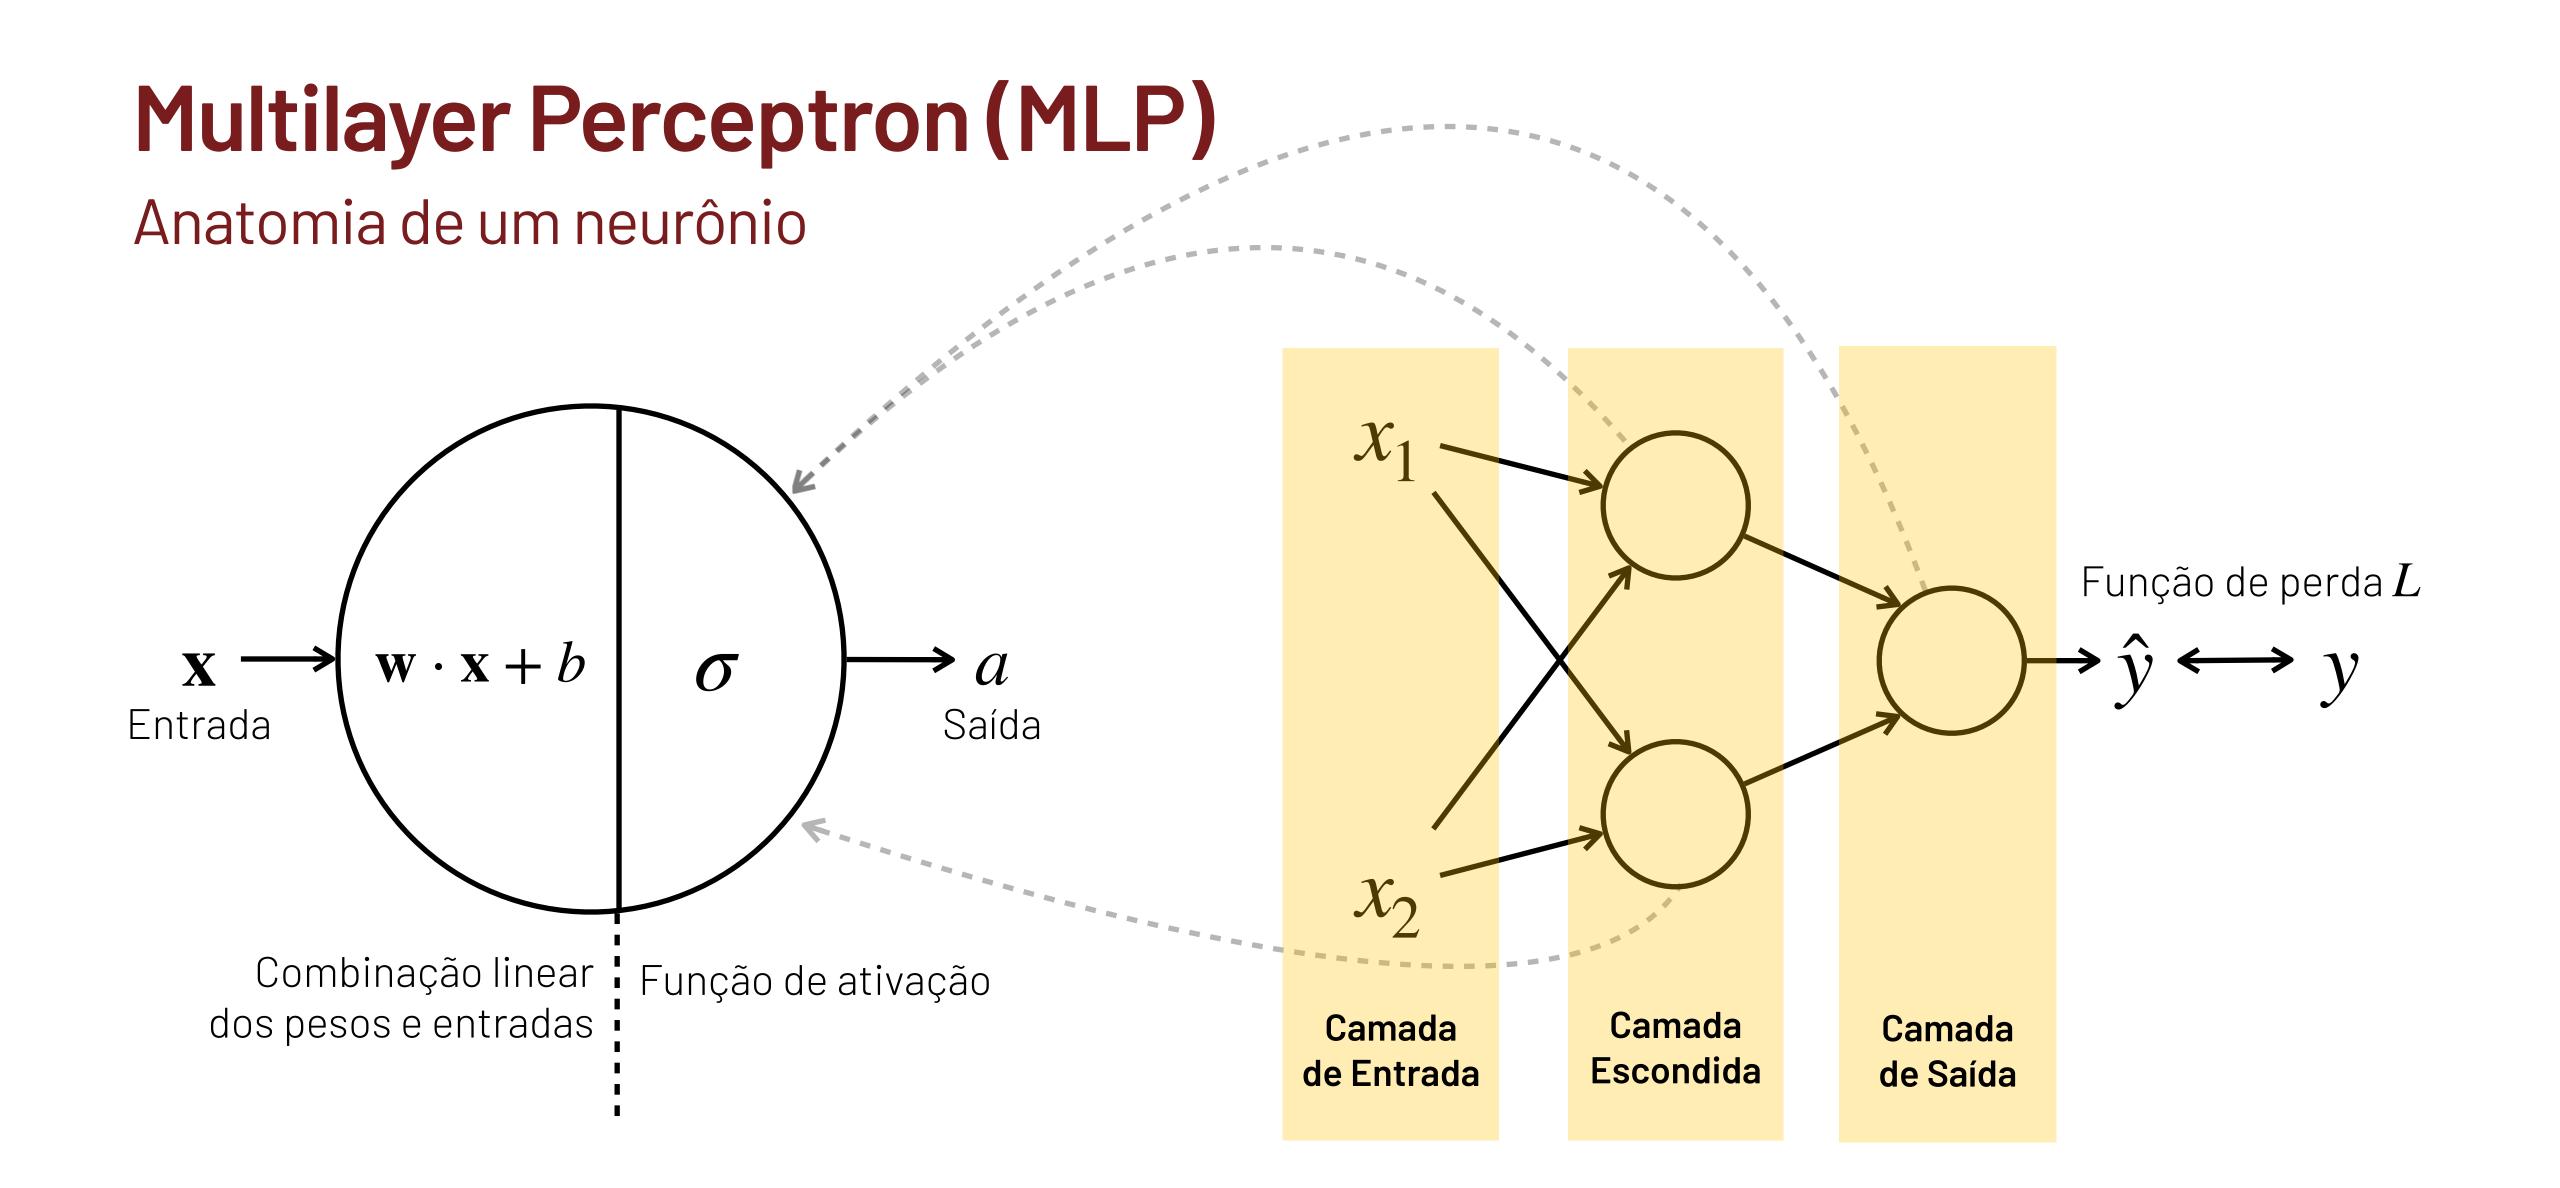


Multilayer Perceptron (MLP)

Algoritmo de classificação (binária ou multiclasse) e regressão que conecta neurônios artificiais em camadas para resolver problemas linarmente não-separáveis









Propagação da Entrada (Forward Pass)

Para um exemplo x

$$\begin{split} a_1 &= \sigma(w_{11}^{[1]}x_1 + w_{12}^{[1]}x_2 + b_1^{[1]}) \\ a_2 &= \sigma(w_{21}^{[1]}x_1 + w_{22}^{[1]}x_2 + b_2^{[1]}) \\ \mathbf{a}^{[1]} &= \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \sigma(\begin{bmatrix} w_{11}^{[1]}x_1 + w_{12}^{[1]}x_2 + b_1^{[1]} \\ w_{21}^{[1]}x_1 + w_{22}^{[1]}x_2 + b_2^{[1]} \end{bmatrix}) \\ &= \sigma(\begin{bmatrix} w_{11}^{[1]} & w_{12}^{[1]} \\ w_{21}^{[1]} & w_{22}^{[1]} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} b_1^{[1]} \\ b_2^{[1]} \end{bmatrix}) = \sigma(W^{[1]}\mathbf{x} + \mathbf{b}^{[1]}) \\ \hat{y} &= \sigma(w_{12}^{[2]}a_1 + w_{12}^{[2]}a_2 + b_1^{[2]}) \\ \hat{y} &= \sigma(\begin{bmatrix} w_{11}^{[2]} & w_{12}^{[2]} \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} + b_1^{[2]}) = \sigma(W^{[2]}\mathbf{a} + b_1^{[2]}) \end{split}$$



Propagação da Entrada (Forward Pass)

Para o conjunto de dados X com n exemplos

$$X = \begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \dots & x_1^{(n)} \\ x_2^{(1)} & x_2^{(2)} & \dots & x_2^{(n)} \end{bmatrix}$$

$$W^{[1]} = \begin{bmatrix} w_{11}^{[1]} & w_{12}^{[1]} \\ w_{21}^{[1]} & w_{22}^{[1]} \end{bmatrix} \quad \mathbf{b}^{[1]} = \begin{bmatrix} b_{1}^{[1]} \\ b_{2}^{[1]} \end{bmatrix}$$

$$A^{[1]} = \sigma(W^{[1]}X + \mathbf{b}^{[1]}) = \sigma(\begin{bmatrix} a_{1}^{(1)} & a_{1}^{(2)} & \dots & a_{1}^{(n)} \\ a_{2}^{(1)} & a_{2}^{(2)} & \dots & a_{2}^{(n)} \end{bmatrix}) \quad \chi_{2}^{(i)}$$
Neurônio 2^[1]

$$W^{[2]} = \begin{bmatrix} w_{11}^{[2]} & w_{12}^{[2]} \end{bmatrix}$$

$$\hat{Y} = \sigma(W^{[2]}A^{[1]} + b^{[2]}) = \begin{bmatrix} \hat{y}^{(1)} & \hat{y}^{(2)} & \dots & \hat{y}^{(n)} \end{bmatrix}$$



Neurônio 1^[2]

Camada[2]

Camada [1]

Hipótese

Hipótese

$$Z^{[1]} = W^{[1]}X + \mathbf{b}^{[1]}$$

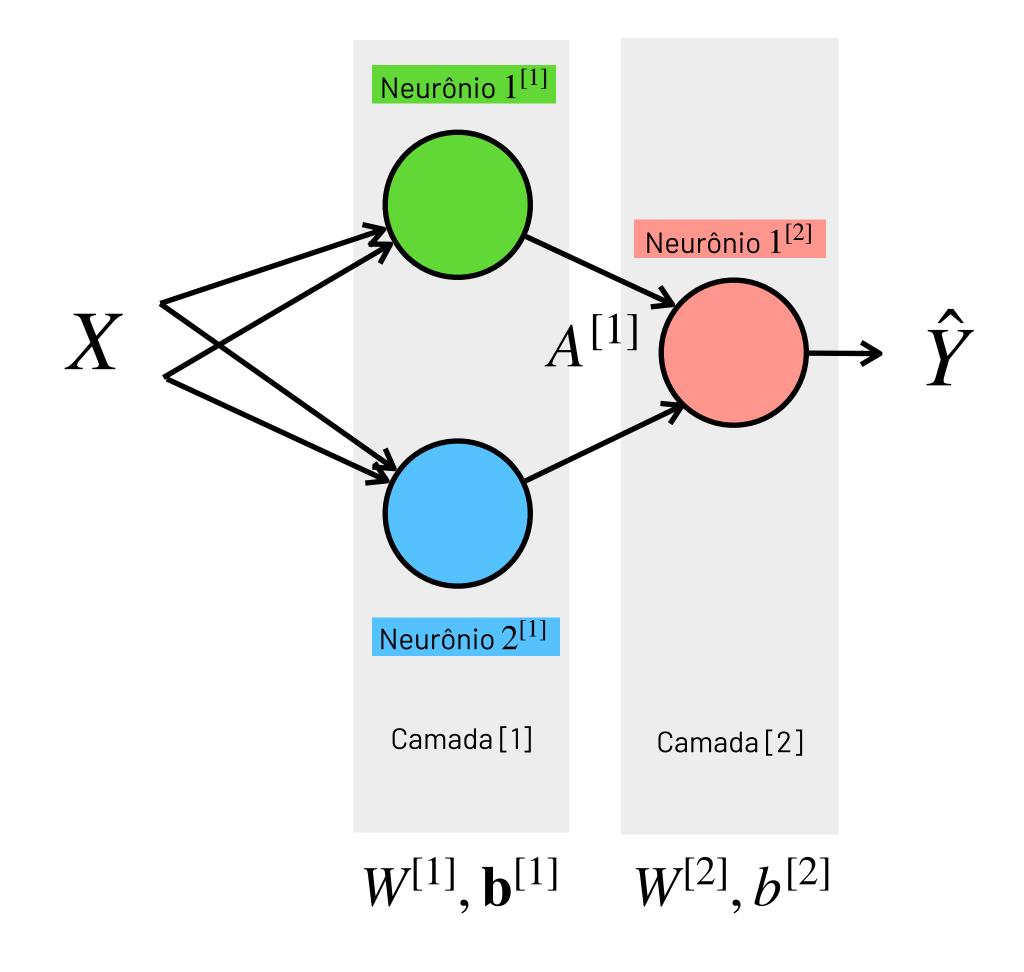
$$A^{[1]} = \sigma(Z^{[1]})$$

$$Z^{[2]} = W^{[2]}\mathbf{a}^{[1]} + b^{[2]}$$

$$\hat{Y} = \sigma(Z^{[2]})$$

$$h(\mathbf{x}) = \sigma(W^{[2]} \cdot \sigma(W^{[1]}X + \mathbf{b}^{[1]}) + b^{[2]}$$
$$h(\mathbf{x}) = \sigma(W^{[2]} \cdot h^{[1]}(X) + b^{[2]})$$

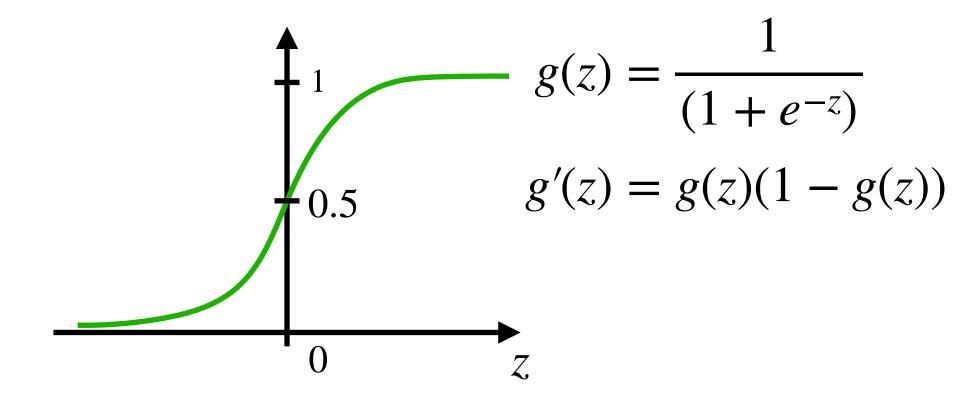
MLPs aprendem funções compostas!



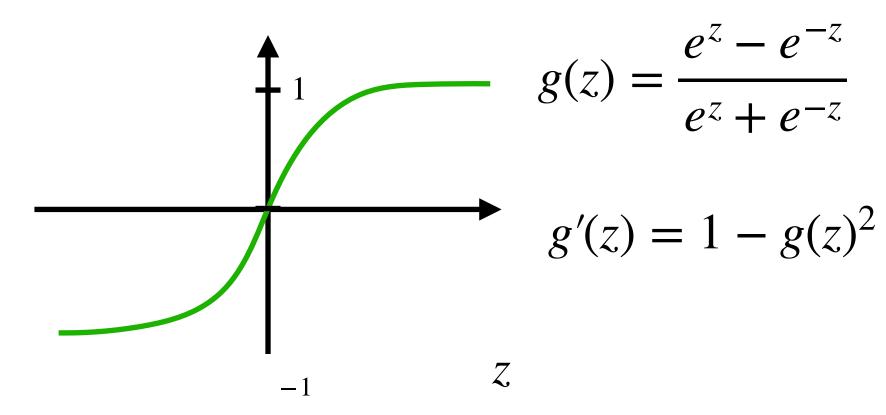


Funções de Ativação

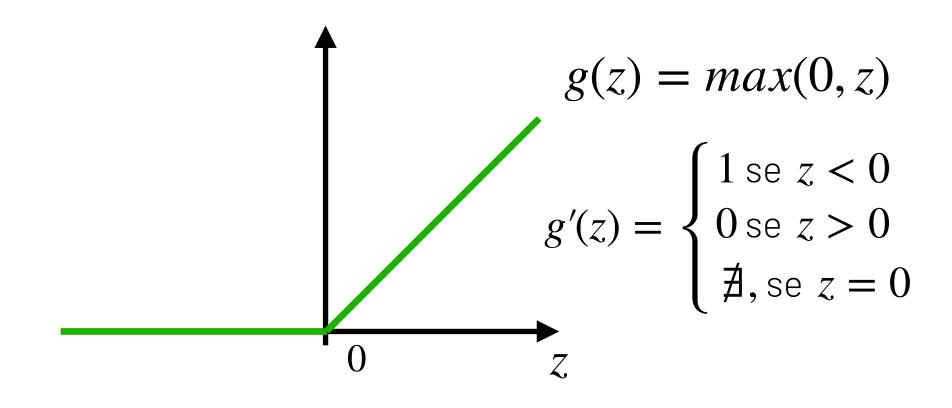
Logística (sigmoide)



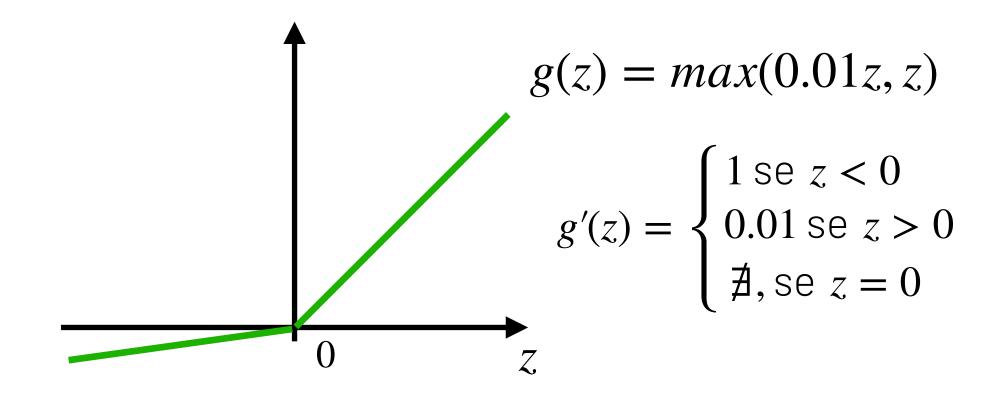
Tangete Hiperbólica



Unidade Linear Retificada (ReLU)



Leaky ReLU





Porque precisamos de funções de ativação não lineares?

$$Z^{[1]} = W^{[1]}X + \mathbf{b}^{[1]}$$
 $A^{[1]} = \sigma(Z^{[1]})$
 $Z^{[2]} = W^{[2]}\mathbf{a}^{[1]} + b^{[2]}$
 $\hat{Y} = \sigma(Z^{[2]})$

Se utilizarmos funções de ativação lineares, a hipótese será linear!

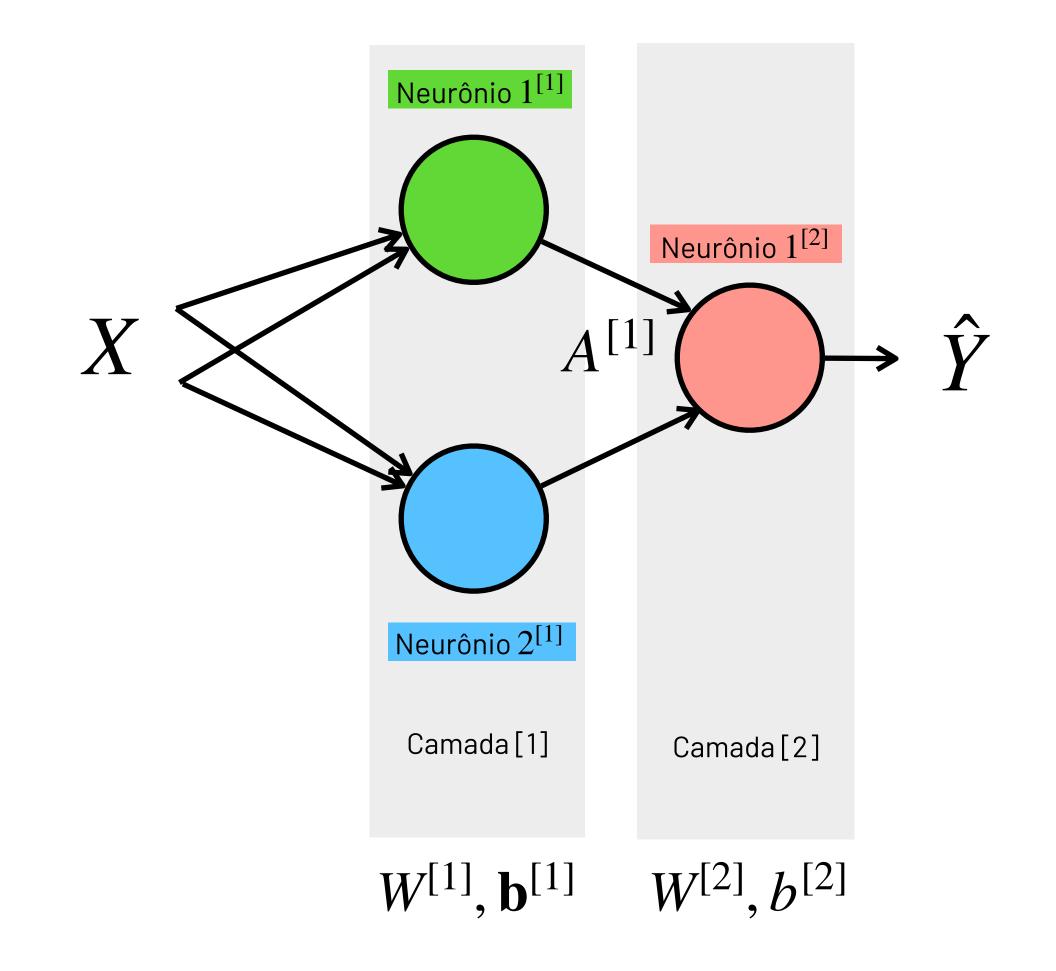
$$h(\mathbf{x}) = \sigma(W^{[2]} \cdot g(W^{[1]} \cdot \mathbf{x} + \mathbf{b}^{[1]}) + b^{[2]})$$

$$h(\mathbf{x}) = W^{[2]} \cdot (W^{[1]} \cdot \mathbf{x} + \mathbf{b}^{[1]}) + b^{[2]}$$

$$h(\mathbf{x}) = (W^{[2]} \cdot W^{[1]}) \cdot \mathbf{x} + (W^{[2]} \cdot \mathbf{b}^{[1]}) + b^{[2]}$$

$$W' \qquad b'$$

$$h(x) = W' \cdot \mathbf{x} + b'$$





Próxima aula

A7: MLP em Numpy

Aula prática sobre implementação de redes neurais profundas com Numpy.

