

INF721

2023/2



Aprendizado em Redes Neurais Profundas

A6: Backpropagation

Logística

Avisos

- ▶ Teste T2: Multilayer Perceptron na próxima aula!

Última aula

- ▶ Problemas linearmente não-separáveis
- ▶ Multilayer Perceptron (MLP)
- ▶ Forward Pass
- ▶ Funções de ativação

Plano de Aula

- ▶ Grafo computacional
- ▶ Gradiente da Regressão Logística
- ▶ Gradiente da MLP

Grafo Computacional

Um grafo dirigido que descreve as expressões matemáticas de uma RNA passo a passo:


- ▶ Vértices representam operações
- ▶ Arestas representam entrada e saída

$$J(a, b, c) = 3(a + bc)$$

$$u = bc$$

$$v = a + u$$

$$J = 3v$$



Grafo Computacional e RNAs


Grafos computacionais nos ajudam a calcular o gradiente de uma função de perda com relação aos pesos de uma RNA

Regressão Logística

$$z = \mathbf{w} \cdot \mathbf{x} + b$$

$$\hat{y} = h(\mathbf{x}) = \frac{1}{1 + e^{-z}}$$

$$L(\hat{y}, y) = -y \log \hat{y} + (1 - y) \log (1 - \hat{y})$$



Retropropagação (Backprop)

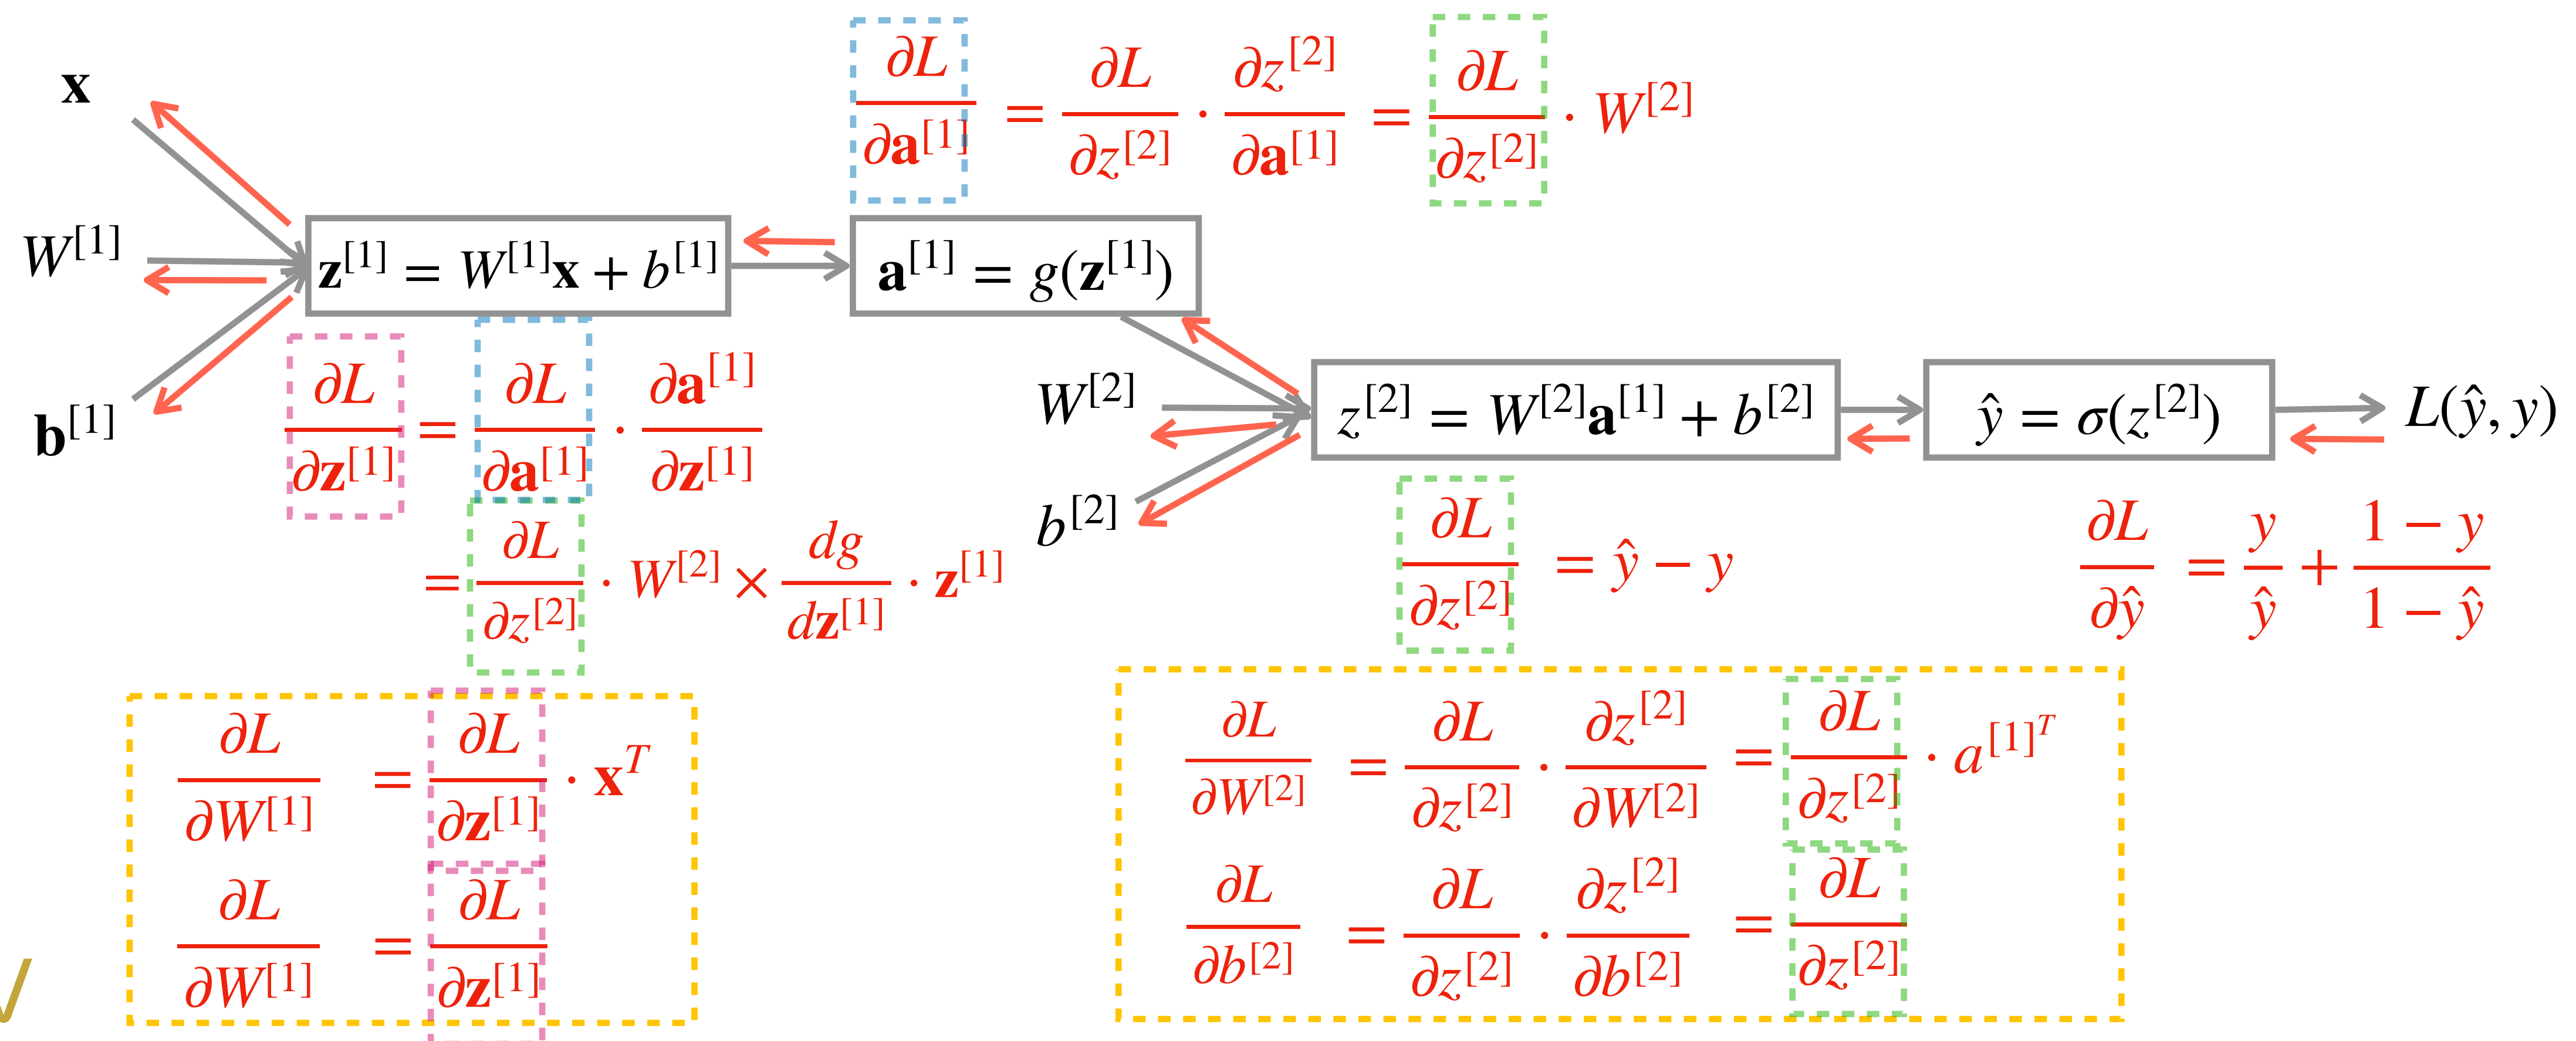
Calcular as derivadas parciais da função de perda com relação aos pesos $W^{[l]}$ e $b^{[l]}$ para todas as camadas l de trás pra frente com a regra da cadeia.

MLP (1 camada escondida)

$$\mathbf{z}^{[1]} = W^{[1]}\mathbf{x} + \mathbf{b}^{[1]} \quad z^{[2]} = W^{[2]}\mathbf{a}^{[1]} + b^{[2]}$$

$$\mathbf{a}^{[1]} = g(\mathbf{z}^{[1]}) \quad \hat{y} = \sigma(z^{[2]})$$

$$L(\hat{y}, y) = -y \log \hat{y} + (1 - y) \log (1 - \hat{y})$$



Backward Pass

MLP (1 camada)

$$Z^{[1]} = W^{[1]}X + \mathbf{b}^{[1]}$$

$$A^{[1]} = \sigma(Z^{[1]})$$

$$Z^{[2]} = W^{[2]}\mathbf{a}^{[1]} + \mathbf{b}^{[2]}$$

$$\hat{Y} = \sigma(Z^{[2]})$$

Função de Perda

$$L(h) = -\frac{1}{n} \sum_{i=1}^n (y_i \log \hat{y}_i + (1 - y_i) \log (1 - \hat{y}_i))$$

Gradiente

$$dZ^{[2]} = \hat{Y} - Y$$

$$dW^{[2]} = \frac{1}{n} dZ^{[2]} \cdot A^{[1]T}$$

$$db^{[2]} = \frac{1}{n} \sum_{i=1}^n dZ_{[:,i]}^{[2]}$$

$$dZ^{[1]} = W^{[2]T} \cdot dZ^{[2]} \times \frac{dg}{dz^{[1]}} \cdot Z^{[1]}$$

$$dW^{[1]} = \frac{1}{n} dZ^{[1]} \cdot X^T$$

$$db^{[1]} = \frac{1}{n} \sum_{i=1}^n dZ_{[:,i]}^{[1]}$$

Inicialização de pesos na MLP

Em RNAs com pelo menos 1 camada escondida (MLPs), temos que inicializar os pesos com valores aleatórios próximos de zero.


Se inicializarmos com zeros, os neurônios da camada escondida serão iguais!

$$W^{[1]} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \quad b^{[1]} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$


$$W^{[2]} = [0 \quad 0]$$

$$\downarrow$$
$$a_1^{(i)} = a_2^{(i)} \longrightarrow dZ_1^{[1]} = dZ_2^{[1]}$$

$$dW = \begin{bmatrix} u & u \\ u & u \end{bmatrix}$$




Ns regiões próximas de zero o gradiente é maior!



Redes Neurais Artificiais Profundas


Regressão Logística

RNA de 1 camada (raza)




1 camada oculta

RNA de 2 camadas (raza)




2 camadas ocultas

RNA de 3 camadas (raza)




5 camadas ocultas

RNA de 6 camadas (profunda)



Redes Neurais Artificiais Profundas

RNA de L camadas



Para um exemplo \mathbf{x} :

$$\begin{aligned} \mathbf{z}^{[1]} &= W^{[1]}\mathbf{x} + \mathbf{b}^{[1]} \\ \mathbf{a}^{[1]} &= g(\mathbf{z}^{[1]}) \\ \mathbf{z}^{[2]} &= W^{[2]}\mathbf{a}^{[1]} + \mathbf{b}^{[2]} \\ \mathbf{a}^{[2]} &= g(\mathbf{z}^{[2]}) \\ &\dots \\ \mathbf{z}^{[L]} &= W^{[L]}\mathbf{a}^{[L-1]} + \mathbf{b}^{[L]} \\ \hat{y} &= \sigma(\mathbf{z}^{[L]}) \end{aligned}$$

Regra geral:


$$\begin{aligned} \mathbf{z}^{[l]} &= W^{[l]}\mathbf{a}^{[l-1]} + \mathbf{b}^{[l]} \\ \mathbf{a}^{[l]} &= g(\mathbf{z}^{[l]}) \end{aligned}$$

Vetorizado

$$\begin{aligned} \mathbf{Z}^{[l]} &= W^{[l]}\mathbf{A}^{[l-1]} + \mathbf{b}^{[l]} \\ \mathbf{A}^{[l]} &= g(\mathbf{Z}^{[l]}) \\ \mathbf{A}^{[0]} &= \mathbf{X} \\ \mathbf{A}^{[L]} &= \hat{\mathbf{Y}} \end{aligned}$$


Funções de ativação na camada de saída

Logística (sigmoide)




Classificação Binária

Linear



Regressão

?



Classificação Multiclasse

Função de ativação softmax para classificação multiclasse

Hipótese

$$Z^{[1]} = W^{[1]}X + \mathbf{b}^{[1]}$$


$$A^{[1]} = g(Z^{[1]})$$

$$Z^{[2]} = W^{[2]}a^{[1]} + \mathbf{b}^{[2]}$$

$$\hat{Y} = \text{softmax}(Z^{[2]})$$

Softmax

$$g(z) = \frac{e^z}{\sum_{j=i}^C e_i^z}$$



Próxima aula

A7: MLP em Numpy

Aula prática sobre implementação de redes neurais profundas com Numpy.